REVISTA SODEBRAS | ISSN 1809-3957
International Sodebras Congress
2026
Goiânia - GO

DESEMPENHO PREDITIVO E CUSTO COMPUTACIONAL DE MÉTODOS CLÁSSICOS DE APRENDIZADO DE MÁQUINA NO DIAGNÓSTICO DE FALHAS DO TENNESSEE EASTMAN PROCESS: UMA AVALIAÇÃO MULTIPROTOCOLO

PREDICTIVE PERFORMANCE AND COMPUTATIONAL COST OF CLASSICAL MACHINE LEARNING METHODS FOR FAULT DIAGNOSIS IN THE TENNESSEE EASTMAN PROCESS: A MULTI-PROTOCOL EVALUATION

Anderson Ricardo de Freitas Rocha[1]
André Felipe Stival Bernardo[1]
Brendon Evangelista Dourado dos Santos[1]
Clarimar José Coelho[2]

Resumo – Este trabalho compara seis métodos clássicos de aprendizado de máquina (regressão logística, SVM, árvore de decisão, Random Forest, gradient boosting por histogramas e XGBoost) no diagnóstico multiclasse de 21 condições do Tennessee Eastman Process, sobre a base pública de Rieth et al. (2017). Em vez de um único experimento, o estudo reúne três protocolos implementados de forma independente pelos autores (P1, P2 e P3), que compartilham a divisão por execução completa e a seleção de hiperparâmetros restrita à validação, mas diferem no volume de treinamento, na amostragem temporal, no rótulo das amostras anteriores à falha, nos hiperparâmetros e no equipamento. Um quarto protocolo, unificado (PU), corrige parte das limitações dos anteriores: treina sobre 5,25 milhões de amostras com três sementes, usa o mesmo número de threads para todos os modelos e avalia uma mesma predição sob as três convenções de rótulo. Na avaliação por amostra, o XGBoost obteve o maior F1 macro (0,800 a 0,824) e o maior MCC (0,750 a 0,811) nos quatro protocolos, e todos os métodos baseados em árvores superaram os lineares em pelo menos 0,19 de F1 macro. As falhas 3, 9 e 15 e a condição normal formaram um bloco de confusão persistente; onde o F1 por classe foi medido, nenhum modelo ultrapassou 0,35 nessas três falhas. A posição de Random Forest, árvore de decisão e gradient boosting variou com o protocolo, e ablações aplicadas ao PU reproduziram inversões específicas ao modificar configurações individuais: limitar a profundidade do Random Forest a 30 níveis reduziu seu F1 macro em 0,044, para abaixo da árvore isolada, e desativar a parada antecipada do gradient boosting, com 200 iterações fixas, reduziu-o em 0,035 e multiplicou por dez a variação entre sementes. Quando as predições de cada execução inteira são agregadas por voto majoritário, o Random Forest supera o XGBoost no PU (F1 macro de 0,882 contra 0,862). A árvore de decisão alcançou de 89% a 96% do F1 macro do XGBoost com inferência de 0,08 a 0,28 µs por amostra. A divisão por amostra inflou o F1 macro em 0,013 a 0,056, e a convenção de rótulo pré-falha alterou-o em quatro a nove pontos. Conclui-se que, nos protocolos e configurações examinados, as classes difíceis e a superioridade das árvores sobre os lineares são estáveis, mas o ranking e as métricas dependem da unidade de divisão, da convenção de rótulo, da granularidade da avaliação e das configurações dos modelos, que precisam ser declaradas para que uma comparação seja interpretável.

Palavras-chave: Tennessee Eastman Process. Diagnóstico de falhas. Aprendizado de máquina. Replicação. Custo computacional.

[1] Mestrado em Automação Industrial e Inteligência Artificial, Pontifícia Universidade Católica de Goiás (PUC Goiás), Goiânia, Goiás, Brasil. Contatos: ricardo.arfr@gmail.com; andre.stival.b@gmail.com; brenndon100@gmail.com.

[2] Professor responsável pela disciplina Modelagem e Simulação, PUC Goiás. Contato: clarimar@pucgoias.edu.br.

Abstract – This work compares six classical machine learning methods (logistic regression, SVM, decision tree, Random Forest, histogram-based gradient boosting and XGBoost) for multiclass diagnosis of 21 conditions of the Tennessee Eastman Process, using the public dataset of Rieth et al. (2017). Instead of a single experiment, the study brings together three protocols implemented independently by the authors (P1, P2 and P3). All three split the data by complete simulation run and select hyperparameters on validation only, but they differ in training volume, temporal sampling, labeling of pre-fault samples, hyperparameters and hardware. A fourth, unified protocol (PU) addresses part of their limitations: it trains on 5.25 million samples with three seeds, uses the same number of threads for every model and evaluates a single prediction under the three labeling conventions. In sample-level evaluation, XGBoost achieved the highest macro F1 (0.800 to 0.824) and MCC (0.750 to 0.811) in all four protocols, and every tree-based method outperformed the linear ones by at least 0.19 macro F1. Faults 3, 9 and 15 and the normal condition formed a persistent confusion block; where per-class F1 was measured, no model exceeded 0.35 on these three faults. The relative position of Random Forest, decision tree and gradient boosting changed with the protocol, and ablations applied to PU reproduced specific inversions by modifying individual configurations: limiting Random Forest depth to 30 levels lowered its macro F1 by 0.044, below the single decision tree, and disabling early stopping in gradient boosting, with 200 fixed iterations, lowered it by 0.035 and increased between-seed variation tenfold. When predictions over each whole run are aggregated by majority vote, Random Forest outperforms XGBoost in PU (macro F1 of 0.882 versus 0.862). The decision tree reached 89% to 96% of XGBoost's macro F1 with inference of 0.08 to 0.28 µs per sample. Sample-level splitting inflated macro F1 by 0.013 to 0.056, and the pre-fault labeling convention changed it by four to nine points. Within the protocols and configurations examined, the difficult classes and the advantage of tree-based over linear models are stable, but rankings and metrics depend on the splitting unit, labeling convention, evaluation granularity and model configuration, which must be declared for a comparison to be interpretable.

Keywords: Tennessee Eastman Process. Fault diagnosis. Machine learning. Replication. Computational cost.

I. INTRODUÇÃO

Processos químicos industriais são monitorados por dezenas de variáveis acopladas, e o diagnóstico de falhas consiste em reconhecer, a partir desses sinais, se a planta opera em regime normal ou sob uma condição anormal específica. O problema é tratado há décadas por métodos estatísticos multivariados (CHIANG; RUSSELL; BRAATZ, 2000; 2001) e, mais recentemente, por aprendizado de máquina (MELO; CÂMARA; PINTO, 2024). O Tennessee Eastman Process (TEP), proposto por Downs e Vogel (1993), tornou-se o ambiente de referência dessa literatura por reproduzir uma planta multivariável, não linear e sujeita a vinte modos de falha (YIN et al., 2012; 2014; MELO et al., 2022).

Formulado como classificação, o diagnóstico no TEP atribui cada leitura dos sensores a uma de 21 classes: a operação normal e as vinte falhas. A versão estendida de Rieth et al. (2017), com 500 execuções independentes por condição, permite tratar a execução completa como unidade experimental. Revisões recentes, porém, apontam que os benchmarks abertos da área são usados com protocolos heterogêneos e pouco declarados, e recomendam bases padronizadas e comparações mais rigorosas (MELO et al., 2022; LEITE et al., 2024).

Para ilustrar a prática corrente, treze trabalhos sobre classificação de falhas no TEP publicados entre 2019 e 2026 foram analisados quanto a protocolo, dados e resultados (Tabela 1). A seleção foi feita em duas etapas, considerando apenas trabalhos com texto completo acessível. Na primeira, buscaram-se no OpenAlex, pelo texto completo, marcas próprias da base de Rieth et al. (2017): o código de registro 6C3JR1 e os termos simulationRun, faultNumber e TEP_Faulty_Training. Foram encontrados 101 trabalhos que citam a base e 31 que citam o artigo que a descreve; destes, cinco são trabalhos revisados por pares que aplicam métodos clássicos de aprendizado de máquina a ela. Na segunda etapa, buscaram-se no Crossref, no OpenAlex e no Semantic Scholar trabalhos de 2021 a 2026 que combinassem o nome do processo com os métodos avaliados (árvore de decisão, Random Forest, gradient boosting, XGBoost, SVM, regressão logística e classificação multiclasse de falhas). Dos quinze localizados, oito foram lidos integralmente e incluídos. Os DOI foram conferidos no Crossref. O primeiro recorte reúne, até onde a busca alcançou, os trabalhos que usam a mesma base com métodos clássicos; o segundo é uma amostra, e não uma revisão sistemática. As proporções da Tabela 1 descrevem esse conjunto, e não toda a literatura. Uma revisão sistemática recente, com meta-análise de estudos de aprendizado profundo no TEP, chegou a conclusão semelhante: o protocolo de avaliação e a omissão seletiva de cenários moldam os resultados publicados, sobretudo nas falhas 3, 9 e 15 (ALVIZ-MEZA et al., 2026). Apenas quatro declaram divisão por execução; os demais dividem por amostra individual ou não informam a unidade de divisão. Como leituras consecutivas de uma execução são quase idênticas, a divisão por amostra permite ao modelo reconhecer vizinhos já vistos, forma de vazamento amplamente documentada (SAEB et al., 2017; KAPOOR; NARAYANAN, 2023). Lyu et al. (2026) observaram que arquiteturas com acurácia acima de 99% perderam até 23 pontos quando avaliadas em dados de um simulador independente.

Tabela 1 – Protocolo experimental em treze trabalhos sobre classificação de falhas no TEP (2019–2026)

Critério	Atendem	Trabalhos
Divisão por execução declarada	4/13	Koçak et al. (2026); Lyu et al. (2026); Avanashilingam e Pandiyath Velayudhan (2026); Khan et al. (2026)

Critério	Atendem	Trabalhos
Tratamento das amostras anteriores à falha declarado	3/13	Koçak et al. (2026); Lyu et al. (2026); Li et al. (2026)
Coeficiente de correlação de Matthews reportado	0/13	nenhum
Custo de inferência e memória medido para todas as famílias comparadas	0/13	nenhum (três reportam custo parcial)
Resultados de RF, SVM ou regressão logística sob divisão por execução, em classificação multiclasse	0/13	nenhum

Fonte: Autores (2026).

A Tabela 1 evidencia três lacunas. A primeira é a convenção de rótulo das amostras anteriores à introdução da falha: fisicamente normais, elas podem ser removidas, rotuladas como normais ou rotuladas com a falha da execução, e apenas três trabalhos dizem qual opção adotaram. A segunda é a ausência de métricas robustas ao desbalanceamento, como o MCC, e de custo computacional medido para todas as famílias. A terceira, mais ampla, é que cada trabalho reporta um único experimento: não se sabe quanto de suas conclusões depende de escolhas particulares de protocolo. A literatura de aprendizado de máquina mostra que resultados obtidos em uma única configuração variam com sementes, implementações e detalhes não declarados (BOUTHILLIER; LAURENT; VINCENT, 2019; PINEAU et al., 2021).

Este trabalho aborda essa terceira lacuna por replicação independente, que é diferente de uma análise controlada dos fatores experimentais. Os três autores implementaram, de forma independente e sobre a mesma base, protocolos para comparar as mesmas seis famílias clássicas: regressão logística, SVM, árvore de decisão, Random Forest, gradient boosting e XGBoost. Os protocolos compartilham princípios (divisão por execução, teste isolado até o congelamento dos hiperparâmetros), mas diferem em volume de dados, amostragem, rótulo pré-falha, hiperparâmetros e equipamento. Confrontar os três mostra quais resultados se repetem apesar dessas escolhas, mas não atribui cada diferença a um fator, pois vários fatores variam ao mesmo tempo. Para examinar as explicações sugeridas pela comparação, um quarto protocolo, unificado (PU), foi executado sobre a base completa, com as melhores práticas dos três, e complementado por ablações que alteram um único fator por vez.

O objetivo é comparar o desempenho preditivo, o comportamento por classe e o custo computacional das seis famílias no diagnóstico multiclasse de falhas do TEP, verificando quais conclusões se mantêm entre três protocolos independentes e um protocolo unificado. Cinco hipóteses orientam a análise, a última desdobrada em três proposições:

- **H1** – os métodos baseados em árvores superam os classificadores lineares em F1 macro e MCC;
- **H2** – XGBoost e Random Forest superam os modelos lineares e a árvore de decisão isolada;
- **H3** – os modelos lineares têm menor desempenho preditivo, porém menor custo computacional;
- **H4** – o modelo de maior desempenho preditivo não é necessariamente o de melhor relação entre desempenho e custo;
- **H5** – entre os protocolos, ainda que os valores absolutos variem, mantêm-se: (H5a) o melhor modelo; (H5b) a ordem entre as famílias; e (H5c) as classes mais difíceis.

As contribuições são: (i) resultados das seis famílias sob divisão por execução, com F1 macro, acurácia balanceada e MCC, em quatro protocolos; (ii) a quantificação do efeito da unidade de divisão e, com uma mesma predição, da convenção de rótulo pré-falha; (iii) a análise das falhas persistentemente difíceis (3, 9 e 15) à luz de sua natureza física; e (iv) a fronteira entre desempenho e custo em três equipamentos, incluindo o pico de memória.

II. METODOLOGIA

2.1 Base de dados e auditoria

Todos os protocolos usam a versão estendida do TEP de Rieth et al. (2017), disponível no Harvard Dataverse (DOI 10.7910/DVN/6C3JR1). As simulações não foram geradas pelos autores; o estudo concentra-se na preparação dos dados, no protocolo, no treinamento e na análise. Cada registro tem três identificadores (faultNumber, simulationRun e sample) e 52 variáveis de processo, sendo 41 medidas (XMEAS) e 11 manipuladas (XMV), amostradas a cada três minutos. A classe 0 é a operação normal, e as classes 1 a 20 são as falhas IDV(1) a IDV(20) de Downs e Vogel (1993).

Cada condição tem 500 execuções independentes em cada partição, com sementes distintas entre treinamento e teste. As execuções de treinamento têm 500 amostras (25 h), com a falha introduzida após a amostra 20; as de teste têm 960 amostras (48 h), com a falha após a amostra 160. Como simulationRun vai de 1 a 500 dentro de cada condição e de cada partição, uma trajetória independente é identificada pelo trio (partição, faultNumber, simulationRun). As auditorias verificaram dimensões, classes, execuções por classe, valores ausentes, infinitos e duplicados (Tabela 2), sem encontrar irregularidades; em P3, a integridade dos arquivos foi verificada por MD5.

Tabela 2 – Caracterização da base de dados

Arquivo	Condições	Execuções	Amostras por execução	Linhas	Ausentes, infinitos, duplicados
FaultFree_Training	1	500	500	250.000	0

Arquivo	Condições	Execuções	Amostras por execução	Linhas	Ausentes, infinitos, duplicados
Faulty_Training	20	10.000	500	5.000.000	0
FaultFree_Testing	1	500	960	480.000	0
Faulty_Testing	20	10.000	960	9.600.000	0

Fonte: Autores (2026), a partir de Rieth et al. (2017).

2.2 Três protocolos independentes e um protocolo unificado

Cada autor definiu e executou seu protocolo sem acesso aos resultados de teste dos demais. Os três obedecem a dois princípios comuns: a execução completa é a unidade indivisível de divisão, e o arquivo de teste só é consultado depois que os hiperparâmetros são congelados pela validação. A padronização, quando aplicada, foi ajustada apenas no treinamento. As diferenças entre eles estão na Tabela 3 e funcionam como fatores de perturbação: um resultado que se repete nos três não depende dessas escolhas.

O protocolo unificado (PU) foi definido depois da comparação entre os três, para examinar as explicações que ela sugeriu. Ele usa a divisão de P1 (400 execuções de treino e 100 de validação por classe, semente 42, com manifesto verificado por SHA-256), todas as amostras, rótulo físico no treino como P3 e treino final com treino e validação reunidos (5,25 milhões de amostras). Cada modelo foi treinado com três sementes, todos com oito threads, e o teste (10,08 milhões de amostras) foi predito uma única vez. Essa mesma predição foi avaliada sob as três convenções de rótulo: pós-falha (descartando as 160 primeiras amostras de todas as execuções, como P1), rótulo físico (como P3) e rótulo da execução. Assim, o efeito da convenção é medido sem nenhuma outra diferença de protocolo. A configuração de cada modelo foi congelada pela validação antes de o teste ser predito, e nenhuma decisão do PU (grade, configuração, sementes ou convenções avaliadas) foi tomada a partir de resultados de teste. O log de execução publicado no repositório, com carimbos de tempo, registra o congelamento das configurações às 21h40 de 9/11/2026 e a primeira predição do teste dois minutos depois. Salvo indicação, os resultados do PU referem-se à convenção pós-falha.

As ablações foram executadas depois do PU, com os mesmos dados, divisão, equipamento e threads, alterando um único fator: (i) Random Forest com a configuração do PU e profundidade máxima de 30, como em P1; e (ii) gradient boosting com a configuração do PU, sem parada antecipada e com 200 iterações fixas, como em P1 e P3, em três sementes; nesse caso, o tratamento é o conjunto dessas duas decisões, que a ablação não separa. Os efeitos medidos são condicionais à configuração do PU e não implicam efeitos idênticos em P1, P2 ou P3. Por serem posteriores e motivadas pela comparação, as ablações são análises explicativas, e não parte da seleção de modelos.

Tabela 3 – Diferenças entre os protocolos

Aspecto	P1 (Santos)	P2 (Bernardo)	P3 (Rocha)	PU (unificado)
Execuções por classe: treino / validação	400 / 100 (semente 42)	400 / 100 (semente 20260908)	100 / 50 (semente fixa)	400 / 100 (semente 42)
Treino final	treino + validação (500 execuções)	400 execuções	100 execuções	treino + validação (500 execuções)
Amostragem temporal	todas as amostras	1 a cada 10 instantes	todas as amostras	todas as amostras
Amostras pré-falha	removidas, inclusive na classe normal	removidas nas execuções com falha	rótulo físico (normal)	rótulo físico no treino; teste avaliado nas três convenções
Registros de treino final	5.040.000	404.000	1.050.000	5.250.000
Registros de teste	8.400.000	848.000	10.080.000	10.080.000 (8.400.000 pós-falha)
Métrica de seleção	F1 macro	acurácia balanceada	F1 macro	F1 macro
Repetições do treino	1	1	5 sementes	3 sementes (42, 123, 2024)
SVM	linear (SGD, hinge)	linear (LinearSVC)	Nyström + SGD	linear (SGD, hinge, classes balanceadas)
Threads	padrão de cada biblioteca	padrão de cada biblioteca	4 a 8, não uniforme	8 para todos os modelos
Equipamento	Ryzen 7 5700X, 8 núcleos, 32 GB, Windows 11	MacBook Pro, Apple M4, 16 GB, macOS 27	Apple M3, 8 GB	Ryzen 7 5700X, 8 núcleos, 32 GB, Windows 11
Software	Python 3.11.9; scikit-learn 1.9.0; XGBoost 3.2.0	Python 3.14.6; scikit-learn 1.9.0; XGBoost 3.4.1	scikit-learn; XGBoost	Python 3.14.5; scikit-learn 1.9.1; XGBoost 3.4.1

Fonte: Autores (2026).

A convenção pré-falha define o que se avalia. P1 e P2 removem as amostras anteriores à falha e medem, portanto, o **diagnóstico pós-início da falha**: dado que a planta já está perturbada, qual é a falha. P3 mantém essas amostras com o rótulo do estado físico (normal), o que se aproxima do **monitoramento da execução inteira** e aumenta a classe normal no teste de 480 mil para 2,08 milhões de amostras. Nenhum dos protocolos usa o rótulo da execução como principal, pois ele trata como falha leituras fisicamente normais; P3 o reporta apenas para comparabilidade com a literatura.

2.3 Modelos e seleção de hiperparâmetros

As seis famílias foram implementadas com scikit-learn (PEDREGOSA et al., 2011) e com a biblioteca XGBoost (CHEN; GUESTRIN, 2016). O gradient boosting usou a implementação por histogramas (HistGradientBoosting) em todos os protocolos (FRIEDMAN, 2001), com parada antecipada apenas no PU; Random Forest segue Breiman (2001) e o SVM, Cortes e Vapnik (1995). Regressão logística e SVM receberam dados padronizados; os modelos de árvores usaram a escala original. Apenas as 52 variáveis entraram nos modelos, sem seleção de atributos, atributos temporais ou reamostragem de classes.

Em P3, o SVM com núcleo gaussiano exato mostrou-se inviável na escala do problema, com custo entre quadrático e cúbico no número de amostras (limitação também relatada por Koçak et al., 2026). Por isso empregou-se a aproximação de Nyström seguida de SVM linear por gradiente estocástico em cinco épocas. Os hiperparâmetros foram escolhidos apenas na validação, por variações controladas dos parâmetros mais influentes (P1 e P2) ou por grade fatorial de 3 a 12 configurações por modelo (P3 e PU). No PU, a busca usou uma a cada cinco amostras do treino, e o treino final usou todas. A Tabela 4 reúne as configurações congeladas antes do teste. O orçamento de busca e a implementação do SVM diferiram entre os protocolos (SVM linear em P1, P2 e PU; aproximação de núcleo RBF em P3); por isso, os resultados caracterizam as implementações e configurações avaliadas, e não as famílias de algoritmos em geral.

Tabela 4 – Configurações finais por protocolo

Modelo	P1	P2	P3	PU
Regressão logística	L2; C = 0,1; SAGA	C = 10; pesos balanceados; L-BFGS	multinomial; C = 10	C = 1; L-BFGS
SVM	SGD hinge; $\alpha = 10^{-5}$	LinearSVC; C = 0,1	Nyström + SGD, 5 épocas	SGD hinge; $\alpha = 10^{-5}$; classes balanceadas
Árvore de decisão	sem limite; folha ≥ 20	profundidade 40; folha ≥ 5	sem limite; folha ≥ 20	sem limite; folha ≥ 20
Random Forest	100 árvores; profundidade 30; folha ≥ 20; sqrt	200 árvores; folha ≥ 5	200 árvores; folha ≥ 20; 30% dos atributos	200 árvores; folha ≥ 20; 30% dos atributos
Gradient boosting	$\eta = 0,05$; 200 iterações; 31 folhas	$\eta = 0,05$; 100 iterações; 31 folhas	configuração mais conservadora	$\eta = 0,05$; 63 folhas; parada antecipada
XGBoost	100 árvores; $\eta = 0,1$; profundidade 8	200 árvores; profundidade 6; $\eta = 0,1$	500 árvores; profundidade 6; $\eta = 0,1$	500 árvores; profundidade 8; $\eta = 0,1$

Fonte: Autores (2026).

Dois achados da seleção se repetiram. Nas árvores, limitar o crescimento pelo número mínimo de amostras por folha foi melhor que limitar a profundidade: em P1 a árvore sem limite alcançou F1 de validação de 0,7579, e em P3 superou em oito pontos qualquer variante limitada. No gradient boosting, P3 observou forte sensibilidade: taxa 0,1 ou 63 folhas degradaram o F1 macro em até 0,05. Com parada antecipada, essa sensibilidade desapareceu no PU: as quatro configurações ficaram entre 0,787 e 0,800 de F1 na validação.

2.4 Métricas e análise estatística

Todos os protocolos calcularam no teste a acurácia balanceada (média das revocações; BRODERSEN et al., 2010), o F1 macro e o MCC multiclasse (GORODKIN, 2004), além de métricas por classe. F1 macro e MCC são as métricas principais: o primeiro dá o mesmo peso às 21 classes, e o segundo resume, na forma multiclasse de Gorodkin (2004), a associação entre classes previstas e verdadeiras; suas vantagens sobre F1 e acurácia foram discutidas para o caso binário por Chicco e Jurman (2020). Também foram medidos tempo de treinamento, tempo de inferência sobre o teste inteiro, tempo por amostra e tamanho do modelo serializado.

Como amostras da mesma execução são dependentes, toda inferência estatística tomou a execução como unidade. A população de referência são execuções de teste geradas pelo mesmo simulador e nas mesmas condições: os testes e intervalos medem a incerteza devida à amostragem dessas execuções, e não a variabilidade decorrente de outras seleções de execuções de treino ou de hiperparâmetros, que só foi tratada parcialmente pela variação entre sementes. Com 10.500 execuções, diferenças pequenas atingem significância estatística; por isso, a interpretação privilegia a magnitude do efeito (diferença em F1 macro, rank-biserial, W de Kendall). O teste de Friedman e o de Wilcoxon comparam a acurácia por execução, e não o F1 macro global; as diferenças de F1 macro e MCC são avaliadas pelos intervalos de bootstrap.

- **P1** – acurácia de cada uma das 10.500 execuções de teste por modelo; teste de Friedman, Wilcoxon pareado com correção de Holm, W de Kendall e correlação rank-biserial (DEMŠAR, 2006);
- **P2** – bootstrap de trajetórias completas estratificado por classe (1.000 réplicas) para o IC 95% de cada modelo e bootstrap pareado (5.000 réplicas) para a diferença entre XGBoost e gradient boosting;

- **P3** – média, desvio-padrão e IC 95% entre cinco sementes; Friedman e Wilcoxon–Holm entre sementes (BENAVOLI; CORANI; MANGILI, 2016); bootstrap pareado das 10.500 execuções de teste (2.000 réplicas) para modelos e pares;
- **PU** – os testes de P1 sobre as 10.500 execuções e o bootstrap por execução de P2 e P3 (1.000 réplicas estratificadas por classe), com IC 95% de F1 macro e MCC para cada modelo e para a diferença entre cada par.

P3 e PU mediram ainda o efeito da unidade de divisão em um piloto com 25 execuções por classe: árvore e Random Forest, com e sem poda, foram treinados sob divisão por execução e sob divisão aleatória por amostra com o mesmo volume, em dez seleções independentes de execuções (SAEB et al., 2017; HAMMERLA; PLÖTZ, 2015).

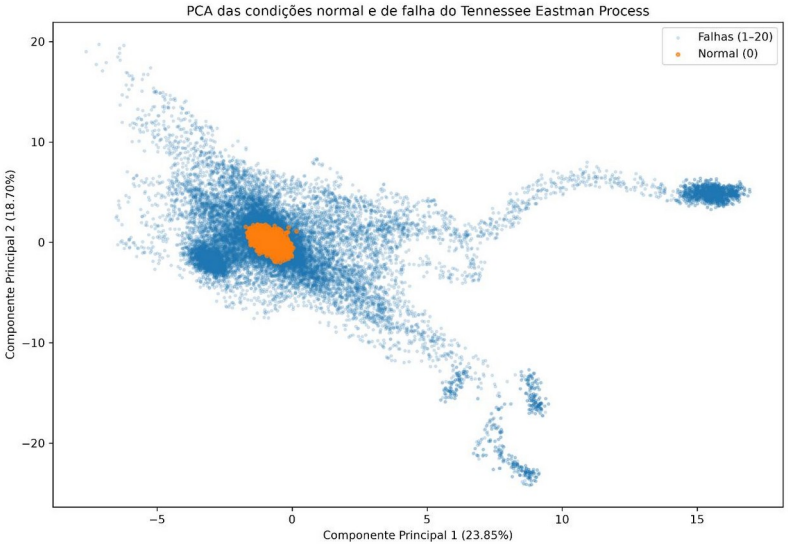
Os tempos são comparáveis apenas dentro de cada protocolo, pois equipamento, volume de teste e paralelismo diferem. Em P3, Random Forest, XGBoost e SVM usaram quatro fios de execução, a árvore foi sequencial e as rotinas de álgebra linear usaram até oito fios. Por isso, entre protocolos, compara-se a ordem dos modelos em custo, não os valores absolutos. No PU, todos os modelos usaram oito threads, e o pico de memória residente foi medido durante o treino e a inferência.

III. RESULTADOS

3.1 Estrutura dos dados e efeito da unidade de divisão

As análises exploratórias de P1 e P3 coincidem: duas componentes principais explicam cerca de 43% da variância (42,6% em P1, sobre 50.400 amostras pós-falha balanceadas; 43,9% em P3, sobre o treinamento), e são necessárias dez para chegar a 74,5%. Há 21 pares de variáveis com correlação absoluta acima de 0,9. A condição normal ocupa uma região concentrada do plano principal, mas parcialmente sobreposta às falhas (Figura 1). As falhas 9, 14, 10, 15 e 19 são as de menor afastamento médio do regime normal (0,007 a 0,014 desvio-padrão), e as falhas 6, 18, 2 e 1, as de maior (1,44 a 9,57). Essa heterogeneidade antecipa as diferenças de dificuldade entre classes.

Figura 1 – PCA das condições normal e de falha do TEP (P1)



Fonte: Autores (2026), a partir de Rieth et al. (2017).

Nos pilotos de P3 e PU (Tabela 5), a divisão aleatória por amostra produziu F1 macro maior que a divisão por execução em todas as dez repetições e nos quatro modelos, com intervalos de confiança que excluem zero. O efeito cresce com a capacidade de memorização: de 0,013 a 0,025 nas versões podadas e de 0,028 a 0,056 nas versões sem poda. No PU, que usa rótulo físico e reserva 20% das execuções para teste, o efeito foi cerca de duas vezes maior que em P3.

Tabela 5 – Efeito da unidade de divisão no F1 macro (25 execuções por classe; dez repetições)

Modelo	P3: por execução	P3: por amostra	P3: Δ [IC 95%]	PU: Δ [IC 95%]
Árvore (folha ≥ 50)	0,717	0,731	+0,013 [0,011; 0,016]	+0,022 [0,020; 0,025]
Árvore sem poda	0,705	0,732	+0,028 [0,025; 0,029]	+0,046 [0,044; 0,049]
Random Forest 50 (folha ≥ 50)	0,760	0,773	+0,013 [0,012; 0,015]	+0,025 [0,022; 0,029]
Random Forest 50 sem poda	0,778	0,807	+0,029 [0,028; 0,031]	+0,056 [0,053; 0,060]

Fonte: Autores (2026).

3.2 Desempenho global nos quatro protocolos

O XGBoost obteve o maior F1 macro, a maior acurácia balanceada e o maior MCC nos quatro protocolos (Tabela 6 e Figura 2). Sua amplitude entre protocolos foi de apenas 0,024 em F1 macro (0,800 a 0,824), menor que a de qualquer outro modelo de árvores. Os quatro métodos baseados em árvores ficaram entre 0,706 e 0,824, e os dois lineares entre 0,428 e 0,512, sem sobreposição entre as famílias em nenhum protocolo. O PU obteve os maiores valores para XGBoost, gradient

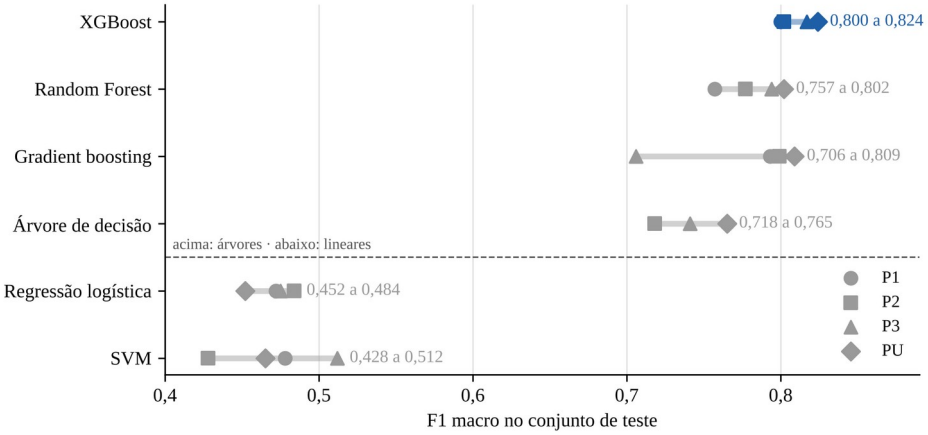
boosting e Random Forest, o que pode refletir o maior volume de treino, interpretação que não foi testada; a acurácia balanceada acompanhou o F1 macro em todos os casos (PU: 0,820 no XGBoost).

Tabela 6 – F1 macro e MCC no conjunto de teste por protocolo

Modelo	F1 macro P1	F1 macro P2	F1 macro P3	F1 macro PU [IC 95%]	MCC P1	MCC P2	MCC P3	MCC PU
XGBoost	**0,800**	**0,802**	**0,817**	**0,824** [0,823; 0,824]	**0,791**	**0,783**	**0,750**	**0,811**
Gradient boosting	0,793	0,799	0,706 ± 0,071	0,809 ± 0,002 [0,809; 0,811]	0,782	0,780	0,645 ± 0,077	0,796
Random Forest	0,757	0,777	0,794	0,802 [0,801; 0,803]	0,743	0,761	0,729	0,787
Árvore de decisão	0,765	0,718	0,741	0,765 [0,764; 0,766]	0,747	0,705	0,656	0,747
SVM	0,478	0,428	0,512 ± 0,038	0,465 [0,464; 0,466]	0,491	0,468	0,500 ± 0,020	0,523
Regressão logística	0,472	0,484	0,475	0,452 [0,451; 0,453]	0,475	0,484	0,553	0,514

Fonte: Autores (2026). P3 = média de cinco sementes, rótulo físico; PU = média de três sementes, convenção pós-falha, IC 95% por bootstrap de execuções; P1 e P2 excluem as amostras pré-falha. Desvio-padrão informado quando ≥ 0,001.

Figura 2 – F1 macro no teste por modelo e protocolo



Fonte: Autores (2026). P3 = média de cinco sementes; PU = média de três sementes, convenção pós-falha.

Abaixo do primeiro lugar, a ordem variou entre os três protocolos independentes, e o PU permitiu examinar as explicações. O gradient boosting foi o segundo em P1 e P2, mas caiu para o quarto lugar em P3, onde foi o único modelo cuja ordenação dependeu da semente (três sementes em torno de 0,75, uma em 0,67 e uma em 0,60). Esse desvio-padrão de 0,071 em P3 contrasta com o de apenas 0,002 no PU, onde o gradient boosting, com parada antecipada, voltou ao segundo lugar; a seção 3.6 isola esse fator. Random Forest superou a árvore isolada em P2 (+0,060) e P3 (+0,053), mas não em P1 (−0,007), único protocolo em que sua profundidade foi limitada a 30 níveis; no PU, sem esse limite, voltou a superá-la (+0,037). O MCC de P3 é menor que o de P1 e P2 porque o rótulo físico quadruplica a classe normal, a mais confundida: no PU, a mesma predição do XGBoost tem MCC de 0,811 na convenção pós-falha e de 0,756 no rótulo físico.

As diferenças são estatisticamente consistentes dentro de cada protocolo. Em P1, o teste de Friedman sobre as 10.500 execuções rejeitou a igualdade entre os seis modelos ($\chi^2(5) = 19.691{,}74$; $p < 0{,}001$; W de Kendall = 0,375), com ranking médio de 1,97 para o XGBoost e 2,53 para o gradient boosting. As 15 comparações pareadas foram significativas após Holm, mas com magnitudes muito diferentes: rank-biserial de 0,351 entre XGBoost e gradient boosting, de 0,098 entre árvore e Random Forest, e de 0,93 a 0,95 entre XGBoost e os lineares. Em P2, a vantagem do XGBoost sobre o gradient boosting foi de 0,00295 em acurácia balanceada [IC 95%: 0,00244; 0,00348], 0,00308 em F1 macro [0,00256; 0,00359] e 0,00381 em MCC [0,00327; 0,00437], e todas as 5.000 réplicas pareadas a favoreceram. Em P3, o bootstrap por execução gerou intervalos de F1 macro com largura inferior a 0,003, e todas as diferenças entre pares excluíram zero; entre sementes, Friedman rejeitou a igualdade (F1 macro: $\chi^2 = 23{,}86$; MCC: $\chi^2 = 23{,}51$; $p < 0{,}001$), mas nenhum par atingiu significância após Holm, limite estrutural de cinco repetições (p mínimo bilateral de 0,0625). No PU, Friedman sobre as 10.500 execuções confirmou o resultado de P1 ($\chi^2(5) = 21.154{,}87$; $p < 0{,}001$; W de Kendall = 0,403), com ranking médio de 1,78 para o XGBoost, 2,78 para o gradient boosting e 3,04 para o Random Forest. As 15 comparações foram significativas após Holm, e todas as diferenças por bootstrap excluíram zero; a menor vantagem do XGBoost foi sobre o gradient boosting, de 0,014 em F1 macro [0,013; 0,014], com rank-biserial de 0,77. Dada a quantidade de execuções, a significância por si só diz pouco: em termos práticos, as diferenças entre XGBoost, gradient boosting e Random Forest (de 0,008 a 0,022 em F1 macro no PU) são pequenas diante da separação entre árvores e lineares (cerca de 0,30) e diante do efeito da convenção de rótulo (até 0,086).

3.3 Desempenho por classe e falhas persistentemente difíceis

As mesmas quatro condições foram as mais difíceis nos quatro protocolos, segundo as métricas disponíveis em cada um (F1 por classe em P1, P3 e PU; revocação e matriz de confusão em P2): as falhas 9, 15 e 3 e a operação normal (Tabela

7). No outro extremo, as falhas 1, 2, 6 e 7 foram reconhecidas com F1 acima de 0,93 por todos os modelos não lineares em P1, P3 e PU, e a falha 7 chegou a 100% de revocação no XGBoost de P2.

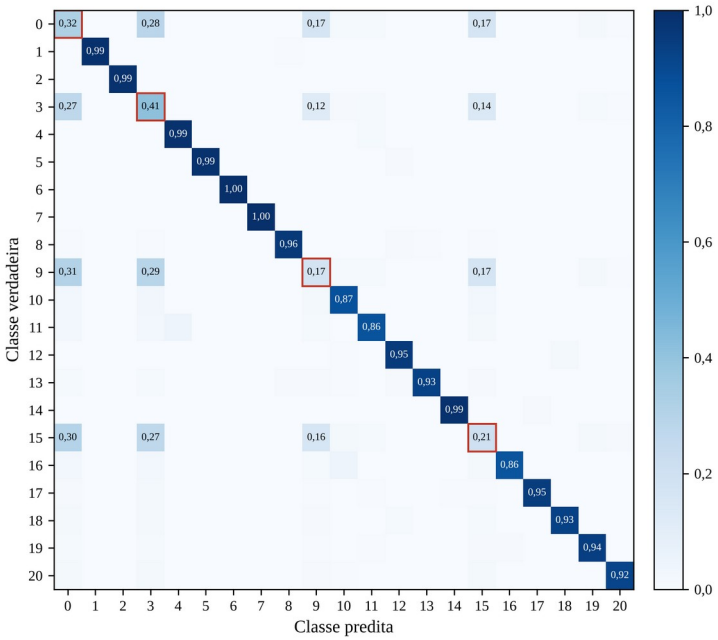
Tabela 7 – Condições de maior dificuldade nos três protocolos

Condição	F1 médio dos 6 modelos: P1	P3	PU	Maior F1 de qualquer modelo: P1	P3 (XGBoost)	PU
Falha 9	0,087	0,098	0,134	0,216 (árvore)	0,160	0,216 (árvore)
Falha 15	0,141	0,104	0,149	0,223 (árvore)	0,171	0,245 (RF)
Falha 3	0,241	0,129	0,198	0,350 (XGBoost)	0,222	0,339 (XGBoost)
Normal (0)	0,187	0,454	0,231	0,261 (XGBoost)	—	0,279 (GB)

Fonte: Autores (2026). Todas as colunas usam F1 por classe. P2 não reportou F1 por classe; a revocação do XGBoost em P2 foi de 15,3% (falha 9), 17,2% (falha 15), 46,3% (falha 3) e 30,5% (normal). Em P3, a classe normal inclui as 160 amostras pré-falha de cada execução, o que eleva seu F1; para P3, o maior F1 por classe disponível é o do XGBoost.

As matrizes de confusão de P2, P3 e PU mostram que essas quatro condições formam um bloco fechado (Figura 3). Em P2, 33,1% dos registros normais receberam o rótulo da falha 3, e 22,1% da falha 3 foram classificados como normais; 34,0% da falha 9 e 32,2% da falha 15 também foram atribuídos à falha 3. Em P3, 33% das amostras das falhas 9 e 15 e 30% da falha 3 foram atribuídas ao regime normal, e 20% das normais à falha 3. No PU, 28% das amostras normais foram atribuídas à falha 3 e 27% da falha 3 ao regime normal; das falhas 9 e 15, de 30% a 31% foram para o normal e de 27% a 29% para a falha 3. Fora do bloco, as matrizes são quase diagonais. Os lineares tiveram F1 nulo nas falhas 3, 9, 15, 10 e 19 no PU. O melhor modelo global não é o melhor em todas as classes: em P1, a árvore de decisão obteve os maiores F1 nas falhas 9 e 15. Em P3, o SVM aproximado não atribuiu a classe normal a nenhuma amostra, embora reconhecesse bem as falhas de grande deslocamento.

Figura 3 – Matriz de confusão normalizada do XGBoost no PU (convenção pós-falha; semente 42); em destaque, o bloco normal–3–9–15



Fonte: Autores (2026).

3.4 Custo computacional e fronteira desempenho–custo

Os custos diferem por ordens de grandeza, e a ordem entre os modelos foi mais estável que os valores (Tabela 8). Nos quatro protocolos, regressão logística e árvore de decisão inferiram em menos de 0,3 µs por amostra; Random Forest gerou o maior arquivo (153 MB a 5,25 GB); e o gradient boosting teve a inferência mais lenta entre os três melhores modelos, por avaliar 21 árvores por iteração.

Tabela 8 – Custo de inferência e tamanho dos modelos

Modelo	Inferência P1 (µs/amostra)	Inferência P2	Inferência P3	Inferência PU	Tamanho P1 (MB)	Tamanho P2	Tamanho P3	Tamanho PU	Pico de memória no treino PU (GB)
Regressão logística	0,27	0,09	0,14	0,24	0,006	0,01	0,01	0,01	2,3

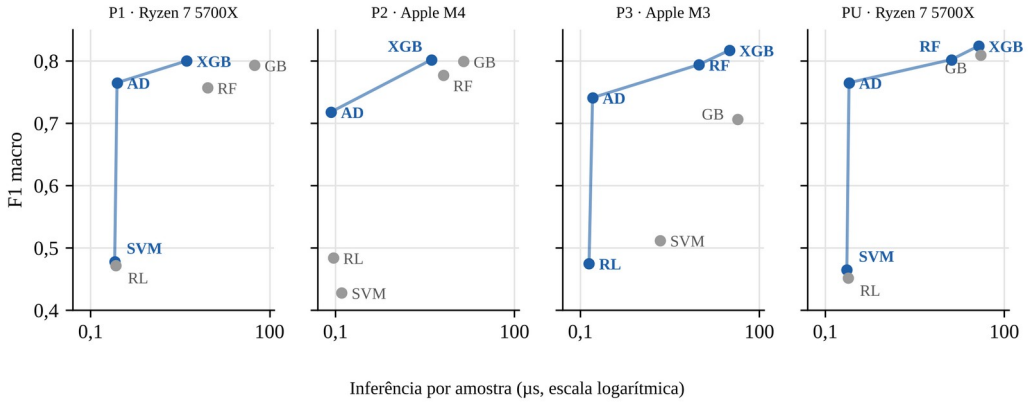
Modelo	Inferência P1 (µs/amostra)	Inferência P2	Inferência P3	Inferência PU	Tamanho P1 (MB)	Tamanho P2	Tamanho P3	Tamanho PU	Pico de memória no treino PU (GB)
SVM	0,25	0,13	2,18	0,23	0,011	0,01	1,1	0,02	2,3
Árvore de decisão	0,28	0,08	0,16	0,25	7,56	3,40	1,8	36,4	0,2
Random Forest	9,10	6,40	9,68	12,95	153,5	1.769,7	286,2	5.251	7,3
Gradient boosting	56,28	14,08	43,28	40,38	5,85	7,35	6,6	18,1	6,1
XGBoost	4,07	4,08	31,44	37,18	8,40	18,97	13,0	101,7	2,5

Fonte: Autores (2026). Inferência em lote sobre 8,4 milhões (P1), 848 mil (P2) e 10,08 milhões (P3 e PU) de amostras, em equipamentos diferentes. Tamanho = arquivo serializado. PU = média de três sementes, oito threads para todos os modelos.

O tempo de treinamento não seguiu o desempenho nem a família. Em P1, com 5,04 milhões de registros, variou de 44 s (SVM) a 908 s (gradient boosting); em P2, com 404 mil, de 29 s (regressão logística) a 348 s (SVM linear, o mais lento); em P3, com 1,05 milhão, de 55 s (SVM aproximado) a 1.266 s (Random Forest). O XGBoost treinou em 633 s, 59 s e 525 s, respectivamente. No PU, com 5,25 milhões de registros e oito threads para todos, o treino variou de 92 s (regressão logística) a 5.655 s (Random Forest, que também atingiu o maior pico de memória, 7,3 GB, e gerou um arquivo de 5,25 GB); o XGBoost levou 3.168 s e a árvore, 739 s.

Na fronteira de Pareto entre F1 macro e inferência por amostra (Figura 4), árvore de decisão e XGBoost aparecem nos quatro protocolos. O gradient boosting foi dominado nos quatro pelo XGBoost, que é melhor e mais rápido. Random Forest foi dominado em P1 e P2, onde o XGBoost inferiu mais rápido, mas entrou na fronteira em P3 e PU, onde o XGBoost com 500 árvores ficou de três a quatro vezes mais lento que ele. O preço do ganho do XGBoost sobre a árvore variou com o protocolo: +0,036 de F1 macro por inferência 15 vezes mais lenta em P1, +0,085 por 49 vezes em P2, +0,077 por 194 vezes em P3 e +0,059 por 149 vezes no PU. Mesmo o modelo mais lento opera seis ordens de grandeza abaixo do intervalo de amostragem de três minutos do TEP. Essa comparação mostra que a inferência não é o gargalo, mas não basta para estabelecer viabilidade operacional: aquisição, comunicação, pré-processamento, resposta do sistema, memória disponível, consumo de energia e requisitos de confiabilidade também contam, e não foram avaliados.

Figura 4 – Fronteira de Pareto entre F1 macro e inferência por amostra, por protocolo



Fonte: Autores (2026). Em azul, os modelos não dominados. XGB = XGBoost; GB = gradient boosting; RF = Random Forest; AD = árvore de decisão; RL = regressão logística.

3.5 Avaliação por execução e convenção de rótulo

Quando as predições de cada execução são agregadas por voto majoritário, o F1 macro sobe em todos os modelos não lineares: em P3, para 0,857 no XGBoost, 0,834 no Random Forest, 0,833 na árvore e 0,831 no gradient boosting; no PU, para 0,882 no Random Forest, 0,862 no XGBoost, 0,861 no gradient boosting e 0,849 na árvore. Nessa granularidade, o Random Forest passa à frente do XGBoost (0,882 contra 0,862). A causa dessa inversão não foi investigada; explicá-la exigiria analisar a distribuição temporal dos erros em cada trajetória. A escolha do melhor classificador depende, portanto, da unidade de avaliação. O voto majoritário usa a execução inteira (800 amostras, cerca de 40 horas após a falha) e não equivale a diagnóstico precoce nem em tempo real. As três tarefas são distintas: detecção (normal ou falha), identificação amostra a amostra (o foco deste trabalho) e diagnóstico retrospectivo por execução.

A convenção de rótulo do teste altera os números na mesma ordem de grandeza que separa os modelos. Em P3, com o rótulo da execução, o F1 macro cai de 0,817 para 0,729 no XGBoost, de 0,794 para 0,708 no Random Forest, de 0,741 para 0,666 na árvore, de 0,706 para 0,628 no gradient boosting, de 0,512 para 0,473 no SVM e de 0,475 para 0,417 na regressão logística. O PU mede o mesmo efeito sem nenhuma outra diferença, pois avalia uma única predição: o F1 macro do XGBoost é 0,824 na convenção pós-falha, 0,826 no rótulo físico e 0,738 no rótulo da execução; nos demais modelos, a queda para o rótulo da execução foi de 4,3 a 8,4 pontos. A queda ocorre porque as 160 amostras pré-falha passam a contar como erro quando o modelo, corretamente, as reconhece como normais. Já as convenções pós-falha e física dão F1 macro quase iguais (diferença de até 0,014), mas MCC diferente, porque mudam a proporção da classe normal.

3.6 Ablações: um fator por vez

As ablações mantiveram tudo o que define o PU (dados, divisão, rótulo, configuração congelada, equipamento e oito threads) e alteraram um único fator (Tabela 9). Limitar a profundidade do Random Forest a 30 níveis, como em P1, reduziu seu F1 macro de 0,802 para 0,758 nas três sementes, em comparação pareada (diferenças de −0,0437 a −0,0442), e o colocou abaixo da árvore de decisão (0,765) em todas elas, reproduzindo em F1 macro a inversão observada em P1 (0,757 contra 0,765). Em MCC, o Random Forest limitado permaneceu à frente da árvore (0,768 contra 0,747), de modo que a inversão depende também da métrica.

Desativar a parada antecipada do gradient boosting e fixar 200 iterações, como em P1 e P3 (um tratamento único, que reúne as duas decisões), reduziu o F1 macro médio de 0,809 para 0,774 e aumentou o desvio-padrão entre sementes de 0,002 para 0,020: as três sementes deram 0,752, 0,783 e 0,788, uma amplitude de 0,036. Com a semente 42, o gradient boosting ficou abaixo da árvore de decisão; com as outras duas, acima. É o mesmo padrão de P3, onde ele foi o único modelo cuja ordenação dependeu da semente. As ablações mostram, portanto, que essas escolhas de configuração bastam para reproduzir as duas inversões no PU. Não mostram que sejam as únicas causas das diferenças entre os protocolos independentes, nem que teriam o mesmo efeito em P1, P2 ou P3.

Tabela 9 – Ablações sobre o PU (convenção pós-falha; apenas o fator indicado foi alterado)

Modelo e configuração	Sementes	F1 macro	MCC	Inferência (µs/amostra)
Random Forest – PU (sem limite de profundidade)	3	0,802	0,787	12,95
Random Forest – PU com profundidade máxima 30	3	0,758 ± 0,000	0,768 ± 0,000	9,08
Árvore de decisão – PU (referência)	3	0,765	0,747	0,25
Gradient boosting – PU (com parada antecipada)	3	0,809 ± 0,002	0,796 ± 0,002	40,38
Gradient boosting – PU sem parada antecipada (200 iterações)	3	0,774 ± 0,020 (0,752; 0,783; 0,788)	0,760 ± 0,020	76,68

Fonte: Autores (2026). Média ± desvio-padrão entre as sementes 42, 123 e 2024, as mesmas em todas as linhas; desvios menores que 0,0005 aparecem como 0,000.

IV. DISCUSSÃO

4.1 Hipóteses

H1 foi sustentada nos quatro protocolos, sem implicar superioridade universal. Todos os métodos baseados em árvores superaram os dois lineares em F1 macro e MCC, com margem mínima de 0,19 de F1 macro (gradient boosting contra SVM aproximado em P3) e de 0,30 no PU. A diferença é compatível com as relações não lineares do TEP (DOWNS; VOGEL, 1993), mas nenhum dos protocolos isolou esse fator como causa: a conclusão se restringe às 52 variáveis instantâneas, às implementações e às configurações usadas.

H2 foi parcialmente sustentada. O XGBoost superou lineares e árvore isolada nos quatro protocolos. O Random Forest superou os lineares sempre e a árvore isolada em P2, P3 e PU, mas não em P1. Uma explicação plausível é a profundidade: P1 foi o único protocolo a limitar a do Random Forest (30 níveis), P3 observou na validação que limitar a profundidade é muito mais prejudicial que limitar o tamanho mínimo da folha, e o PU, sem esse limite, voltou a ter o Random Forest à frente (+0,037). Como o PU também difere de P1 em outros fatores, essa comparação não isolaria a causa; a ablação o fez: com todo o resto do PU mantido, limitar a profundidade a 30 níveis levou o Random Forest de 0,802 para 0,758 de F1 macro, abaixo da árvore (0,765). A ablação mostra que essa configuração basta para reproduzir, no PU, a exceção de P1 em F1 macro; não mostra que seja a única diferença relevante entre P1 e o PU.

H3 foi sustentada para inferência e tamanho, mas não para treinamento. Os lineares tiveram os menores modelos e estiveram entre os mais rápidos na inferência em todos os protocolos, embora no PU tenham exigido mais memória no treino (2,3 GB) que a árvore (0,2 GB). No treinamento, porém, o SVM linear foi o modelo mais lento de P2 (348 s) e a regressão logística levou 228 s em P1, mais que a árvore de P2 e P3. O custo de treinamento depende mais do otimizador e da implementação do que da família.

H4 foi sustentada. O modelo de maior desempenho não ofereceu a melhor relação desempenho–custo em nenhum protocolo, considerando tempo de inferência e tamanho; memória, consumo de energia e requisitos de confiabilidade também pesariam numa escolha operacional. A árvore de decisão esteve na fronteira de Pareto nos quatro protocolos, com 89% a 96% do F1 macro do XGBoost e inferência de 0,08 a 0,28 µs por amostra. O gradient boosting, segundo colocado em P1, P2 e PU, foi dominado nos quatro na fronteira bidimensional entre F1 macro e tempo de inferência. Com outros objetivos a fronteira pode mudar: o gradient boosting, por exemplo, gerou arquivos menores que o XGBoost em todos os protocolos. A escolha depende do requisito: se cada ponto de F1 importa, o XGBoost; se a latência ou a memória do equipamento são restritas, a árvore. Vale notar que a árvore selecionada em P3 tem profundidade 82 e cerca de 18 mil folhas, de modo que seu baixo custo não implica regras legíveis.

H5 foi sustentada apenas parcialmente. H5c foi sustentada: o bloco de confusão entre normal, 3, 9 e 15 apareceu em todos os protocolos. H5b foi sustentada para a separação entre árvores e lineares, mas não para a ordem entre Random Forest, árvore e gradient boosting, que mudou entre os protocolos independentes. H5a foi sustentada na avaliação por

amostra, em que o XGBoost ficou em primeiro nos quatro protocolos, mas não na avaliação por execução, em que o Random Forest o superou no PU. As ablações mostraram que duas escolhas de configuração (profundidade limitada no Random Forest de P1 e ausência de parada antecipada no gradient boosting de P3) bastam para reproduzir as inversões quando reintroduzidas no PU; sem elas, a ordem por amostra foi XGBoost > gradient boosting > Random Forest > árvore. Um estudo de protocolo único reportaria essas posições como se fossem propriedades das famílias.

4.2 Por que as falhas 3, 9 e 15 são difíceis

O bloco de confusão tem uma explicação física plausível, embora não demonstrada pelos experimentos deste trabalho. Na definição de Downs e Vogel (1993), a falha 3 é um degrau na temperatura da alimentação D; a falha 9 é uma variação aleatória nessa mesma temperatura; e a falha 15 é o travamento da válvula de água de resfriamento do condensador. As três atuam em variáveis cujas perturbações tendem a ser compensadas pelas malhas de controle da planta, o que deixaria pouca assinatura nas 52 variáveis medidas. A análise exploratória de P3 é coerente com essa leitura: as falhas 9 e 15 estão entre as de menor afastamento médio do regime normal (cerca de 0,01 desvio-padrão). No PU, mesmo com 5,25 milhões de amostras de treino, nenhum modelo passou de 0,34 de F1 nessas três falhas, e os lineares não acertaram nenhuma.

Essa dificuldade é conhecida desde os primeiros estudos do TEP, que relatam taxas de detecção muito baixas para essas três falhas com métodos multivariados clássicos (CHIANG; RUSSELL; BRAATZ, 2000; YIN et al., 2012). Koçak et al. (2026) descrevem, sobre a mesma base, um "triângulo de confusão" entre normal, falha 9 e falha 15, e Lyu et al. (2026) chegam a excluir as três falhas por sua semelhança com o regime normal. Descritivamente, a falha 3 recebe boa parte das amostras das falhas 9 e 15 (em P2 e no PU); a origem comum das falhas 3 e 9 na temperatura da alimentação D é uma hipótese compatível com essa observação, não um mecanismo demonstrado.

A consequência para a classe normal é direta. Seu F1 baixo em P1 (0,187) não indica que o regime normal seja difícil em si, mas que ele recebe e cede amostras para essas três falhas. Em uma aplicação, isso se traduziria em alarmes falsos de falha 3 durante a operação normal e em falhas 9 e 15 não detectadas, o que impede recomendar qualquer dos modelos para implantação industrial sem tratamento específico dessas classes.

4.3 Comparação com a literatura

Os valores obtidos são coerentes com a única referência publicada de métodos clássicos sobre esta base. Sokolov, Pyatnitsky e Alabugin (2019) relatam acurácia de 0,67 para o Random Forest e 0,46 para a regressão logística, com o rótulo da execução e sem validação separada declarada; sob o mesmo rótulo, P3 obteve 0,660 e 0,432. Na avaliação por execução, Koçak et al. (2026) obtiveram F1 macro de 0,952 ± 0,004 com XGBoost, contra 0,857 em P3. Uma hipótese plausível para a diferença de 9,5 pontos são as 312 características estatísticas de janela temporal construídas por aqueles autores, contra o vetor instantâneo bruto usado aqui; outras diferenças de protocolo, porém, também podem contribuir.

O efeito da unidade de divisão foi menor do que a literatura de vazamento sugeriria: de 0,013 a 0,056 de F1 macro, conforme o modelo e o desenho do piloto. Os colapsos de até 23 pontos relatados por Lyu et al. (2026) decorrem de mudança de distribuição entre simuladores e de janelas temporais sobrepostas, nas quais amostras vizinhas compartilham quase todo o conteúdo (HAMMERLA; PLÖTZ, 2015). Com vetores instantâneos, o vazamento é sistemático e cresce com a capacidade de memorização do modelo; em modelos sem poda, chega à ordem da diferença entre XGBoost e árvore (0,059 no PU), o que basta para alterar um ranking. Já a convenção de rótulo pré-falha mudou o F1 macro em até 8,8 pontos, mais do que separa o primeiro do terceiro colocado em qualquer protocolo. Como apenas três dos treze trabalhos da Tabela 1 declaram essa convenção, comparações numéricas entre estudos do TEP devem ser lidas com cautela.

4.4 Aplicabilidade industrial

Nenhum dos modelos avaliados é adequado, sozinho, ao diagnóstico industrial do TEP. Com F1 abaixo de 0,35 nas falhas 3, 9 e 15 mesmo nos melhores modelos, um sistema baseado neles deixaria de identificar a maior parte dessas falhas e geraria alarmes falsos de falha 3 durante a operação normal. O que os resultados sustentam é um papel mais restrito: os classificadores reconhecem de forma confiável as falhas de grande deslocamento (F1 acima de 0,93 nas falhas 1, 2, 6 e 7) e poderiam compor um sistema em que o bloco normal–3–9–15 seja tratado por atributos temporais, por modelos dedicados ou pela avaliação por execução, além de validação em dados reais.

4.5 Ameaças à validade

- **Protocolos não fatoriais.** Os três protocolos independentes variam vários fatores ao mesmo tempo. O PU isolou o efeito da convenção de rótulo, e as ablações isolaram as duas explicações principais, mas os demais fatores (volume, amostragem, equipamento) não foram variados um de cada vez.
- **Busca de hiperparâmetros limitada e implementações distintas.** As grades foram reduzidas, e o orçamento de busca e a implementação do SVM variaram entre protocolos; os resultados caracterizam as implementações avaliadas. Gradient boosting e SVM aproximado de P3 são os mais afetados, o primeiro por instabilidade sem parada antecipada, o segundo por depender de épocas, componentes e pesos de classe.
- **Variação das execuções de treinamento.** P1 e P2 treinaram uma vez; P3 e PU mantiveram as execuções fixas entre sementes. A variação decorrente de outras seleções de execuções de treinamento não foi medida, e os intervalos por bootstrap refletem apenas a amostragem das execuções de teste.

- **Custo.** Os tempos de P1, P2 e P3 foram medidos em três equipamentos, com paralelismo não uniforme. O PU uniformizou as threads e mediu o pico de memória, mas em um único equipamento; os tempos valem como ordem relativa.
- **Resolução temporal.** A amostragem de 1 a cada 10 instantes de P2 reduz o volume e pode perder mudanças rápidas, embora seus resultados tenham ficado próximos aos de P1.
- **Dados simulados.** Todos os dados vêm de um único gerador; a transferência para simulações independentes ou plantas reais não foi avaliada (LYU et al., 2026).

V. CONCLUSÃO

Este trabalho comparou seis famílias clássicas de aprendizado de máquina no diagnóstico de 21 condições do Tennessee Eastman Process por meio de três protocolos independentes e de um protocolo unificado. Todos dividiram os dados por execução completa e isolaram o teste até o congelamento dos hiperparâmetros; os três primeiros diferiram em volume, amostragem, rótulo pré-falha, configurações e equipamento, e o unificado corrigiu parte das limitações identificadas na comparação entre eles.

Na avaliação por amostra, o XGBoost foi o melhor modelo nos quatro protocolos, com F1 macro de 0,800 a 0,824 e MCC de 0,750 a 0,811; na avaliação por execução do PU, por voto majoritário sobre a trajetória inteira (que não equivale a diagnóstico em tempo real), o Random Forest o superou (0,882 contra 0,862), e os métodos baseados em árvores superaram os lineares por pelo menos 0,19 de F1 macro. As falhas 3, 9 e 15 e a condição normal formaram, em todos, um bloco de confusão compatível com a natureza física dessas falhas. A árvore de decisão foi a alternativa de menor custo com desempenho não linear, presente na fronteira desempenho–custo em todos os protocolos. A ordem entre Random Forest, árvore e gradient boosting variou entre os protocolos, e as ablações mostraram que duas escolhas de configuração bastam para reproduzir as inversões no PU: a profundidade limitada do Random Forest e a ausência de parada antecipada do gradient boosting, que também tornou o modelo instável entre sementes. Os custos absolutos dependeram do equipamento.

Duas escolhas de protocolo pesaram mais que outras. A divisão por amostra inflou o F1 macro em 0,013 a 0,056, efeito sistemático que cresce com a capacidade de memorização. A convenção de rótulo pré-falha, medida no PU sobre uma mesma predição, mudou-o em 4,3 a 8,6 pontos, magnitude comparável à que separa os modelos. Por isso, os resultados de P1, P2 e PU na convenção pós-falha devem ser lidos como **diagnóstico pós-início da falha**, isto é, a identificação da falha depois que ela já ocorreu; eles não representam o monitoramento contínuo da execução inteira, mais próximo do cenário de P3.

A principal conclusão é metodológica: no TEP, nenhuma comparação entre classificadores é inteiramente interpretável sem que se declarem a unidade de divisão, a convenção de rótulo, a granularidade da avaliação e as configurações dos modelos. Cada uma dessas escolhas alterou métricas ou o ranking em magnitude comparável à diferença entre os melhores modelos.

Os resultados valem para dados simulados, variáveis instantâneas sem informação temporal e buscas de hiperparâmetros reduzidas, e seus intervalos de confiança não incluem a variabilidade de novas seleções de execuções de treino. Como continuidade, recomenda-se: (i) incorporar características de janela temporal, que na literatura acrescentam cerca de dez pontos e podem separar as falhas 3, 9 e 15; (ii) estender as ablações a um desenho fatorial dos demais fatores de protocolo (volume, amostragem, rótulo no treino); (iii) reamostrar as execuções de treinamento entre repetições; e (iv) avaliar a transferência para simulações independentes, como o conjunto de Reinartz, Kulahci e Ravn (2021). Qualquer avaliação adicional deve preservar a divisão por execução e declarar a convenção de rótulo.

Disponibilidade de dados e código. A base de dados é pública (RIETH et al., 2017; DOI 10.7910/DVN/6C3JR1). O script do protocolo unificado e das ablações, o manifesto de divisão (SHA-256 091129ecf5aab406…), as configurações congeladas, as métricas por modelo, semente e classe e os metadados de ambiente estão disponíveis em https://github.com/BrendonDourado/tep-avaliacao-multiprotocolo. As configurações de P1, P2 e P3 estão descritas nas Tabelas 3 e 4.

VI. REFERÊNCIAS

ALVIZ-MEZA, A. et al. Selective reporting and evaluation protocol shape the evidence on deep learning fault detection in the Tennessee Eastman Process: a systematic review and meta-analysis. **Machine Learning and Knowledge Extraction**, v. 8, n. 11, art. 349, 2026. DOI: 10.3390/make8110349.

AVANASHILINGAM, J. B.; PANDIYATH VELAYUDHAN, B. Explainable and trustworthy AI for fault classification in the Tennessee Eastman Process: a step toward industrial autonomy. In: PHM SOCIETY ASIA-PACIFIC CONFERENCE, 5., 2025. **Proceedings** [...]. PHM Society, 2026. DOI: 10.36001/phmap.2025.v5i1.4633.

BENAVOLI, A.; CORANI, G.; MANGILI, F. Should we really use post-hoc tests based on mean-ranks? **Journal of Machine Learning Research**, v. 17, n. 5, p. 1-10, 2016.

BOUTHILLIER, X.; LAURENT, C.; VINCENT, P. Unreproducible research is reproducible. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019, Long Beach. **Proceedings** [...]. PMLR, 2019. p. 725-734.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001. DOI: 10.1023/A:1010933404324.

BRODERSEN, K. H.; ONG, C. S.; STEPHAN, K. E.; BUHMANN, J. M. The balanced accuracy and its posterior distribution. In: INTERNATIONAL CONFERENCE ON PATTERN RECOGNITION, 20., 2010, Istanbul. **Proceedings** [...]. Piscataway: IEEE, 2010. p. 3121-3124. DOI: 10.1109/ICPR.2010.764.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. **Proceedings** [...]. New York: ACM, 2016. p. 785-794. DOI: 10.1145/2939672.2939785.

CHIANG, L. H.; RUSSELL, E. L.; BRAATZ, R. D. Fault diagnosis in chemical processes using Fisher discriminant analysis, discriminant partial least squares, and principal component analysis. **Chemometrics and Intelligent Laboratory Systems**, v. 50, n. 2, p. 243-252, 2000. DOI: 10.1016/S0169-7439(99)00061-1.

CHIANG, L. H.; RUSSELL, E. L.; BRAATZ, R. D. **Fault detection and diagnosis in industrial systems**. London: Springer, 2001. DOI: 10.1007/978-1-4471-0347-9.

CHICCO, D.; JURMAN, G. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. **BMC Genomics**, v. 21, n. 1, art. 6, 2020. DOI: 10.1186/s12864-019-6413-7.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, p. 273-297, 1995. DOI: 10.1007/BF00994018.

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. **Journal of Machine Learning Research**, v. 7, p. 1-30, 2006.

DOWNS, J. J.; VOGEL, E. F. A plant-wide industrial process control problem. **Computers & Chemical Engineering**, v. 17, n. 3, p. 245-255, 1993. DOI: 10.1016/0098-1354(93)80018-I.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189-1232, 2001. DOI: 10.1214/aos/1013203451.

GORODKIN, J. Comparing two K-category assignments by a K-category correlation coefficient. **Computational Biology and Chemistry**, v. 28, n. 5-6, p. 367-374, 2004. DOI: 10.1016/j.compbiolchem.2004.09.006.

HAMMERLA, N. Y.; PLÖTZ, T. Let's (not) stick together: pairwise similarity biases cross-validation in activity recognition. In: ACM INTERNATIONAL JOINT CONFERENCE ON PERVASIVE AND UBIQUITOUS COMPUTING, 2015, Osaka. **Proceedings** [...]. New York: ACM, 2015. p. 1041-1051. DOI: 10.1145/2750858.2807551.

KAPOOR, S.; NARAYANAN, A. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, art. 100804, 2023. DOI: 10.1016/j.patter.2023.100804.

KHAN, A. et al. Early-warning industrial fault detection based on physics-guided residual learning and calibrated CRNNs. **Scientific Reports**, v. 16, art. 17488, 2026. DOI: 10.1038/s41598-026-48227-6.

KOÇAK, N. F.; SAYGIN, A.; TÜRK, F.; KARADENIZ, A. M. Run-level fault detection and SHAP-based diagnosis of persistent classification difficulty in the Tennessee Eastman Process. **Processes**, v. 14, n. 16, art. 2569, 2026. DOI: 10.3390/pr14162569.

LEITE, D.; ANDRADE, E.; RÁTIVA, D.; MACIEL, A. M. A. Fault detection and diagnosis in Industry 4.0: a review on challenges and opportunities. **Sensors**, v. 25, n. 1, art. 60, 2024. DOI: 10.3390/s25010060.

LI, D.; XUE, Y.; FU, J.; TAN, T.; YANG, Y.; NIE, J. An evolutionary weighted feature influence factor feature selection method for fault detection in the Tennessee Eastman complex chemical process. **Scientific Reports**, v. 16, art. 19405, 2026. DOI: 10.1038/s41598-026-49874-5.

LYU, N. et al. Benchmarking machine learning fault detection methods on the Tennessee Eastman Process dataset. **ChemRxiv**, 27 jan. 2026. Preprint, não revisado por pares. DOI: 10.26434/chemrxiv.10001628/v1.

MELO, A.; CÂMARA, M. M.; CLAVIJO, N.; PINTO, J. C. Open benchmarks for assessment of process monitoring and fault diagnosis techniques: a review and critical analysis. **Computers & Chemical Engineering**, v. 165, art. 107964, 2022. DOI: 10.1016/j.compchemeng.2022.107964.

MELO, A.; CÂMARA, M. M.; PINTO, J. C. Data-driven process monitoring and fault diagnosis: a comprehensive survey. **Processes**, v. 12, n. 2, art. 251, 2024. DOI: 10.3390/pr12020251.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

PINEAU, J. et al. Improving reproducibility in machine learning research (a report from the NeurIPS 2019 reproducibility program). **Journal of Machine Learning Research**, v. 22, n. 164, p. 1-20, 2021.

REINARTZ, C.; KULAHCI, M.; RAVN, O. An extended Tennessee Eastman simulation dataset for fault-detection and decision support systems. **Computers & Chemical Engineering**, v. 149, art. 107281, 2021. DOI: 10.1016/j.compchemeng.2021.107281.

RIETH, C. A.; AMSEL, B. D.; TRAN, R.; COOK, M. B. Additional Tennessee Eastman Process simulation data for anomaly detection evaluation. **Harvard Dataverse**, V1, 2017. Conjunto de dados. DOI: 10.7910/DVN/6C3JR1.

SAEB, S.; LONINI, L.; JAYARAMAN, A.; MOHR, D. C.; KORDING, K. P. The need to approximate the use-case in clinical machine learning. **GigaScience**, v. 6, n. 5, 2017. DOI: 10.1093/gigascience/gix019.

SOKOLOV, A. N.; PYATNITSKY, I. A.; ALABUGIN, S. K. Applying methods of machine learning in the task of intrusion detection based on the analysis of industrial process state and ICS networking. **FME Transactions**, v. 47, n. 4, p. 782-789, 2019. DOI: 10.5937/fmet1904782s.

YIN, S.; DING, S. X.; HAGHANI, A.; HAO, H.; ZHANG, P. A comparison study of basic data-driven fault diagnosis and process monitoring methods on the benchmark Tennessee Eastman process. **Journal of Process Control**, v. 22, n. 9, p. 1567-1581, 2012. DOI: 10.1016/j.jprocont.2012.06.009.

YIN, S.; DING, S. X.; XIE, X.; LUO, H. A review on basic data-driven approaches for industrial process monitoring. **IEEE Transactions on Industrial Electronics**, v. 61, n. 11, p. 6418-6428, 2014. DOI: 10.1109/TIE.2014.2301773.

VII. COPYRIGHT

Direitos autorais: os autores são os únicos responsáveis pelo material incluído no artigo.